Assignment 3 Benchmark Tasks Report

Benchmark 1

實驗設定

- Model A: `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2`
- Model B: `sentence-transformers/all-MiniLM-L6-v2`
- 相同切塊參數： `chunk_size=1000` , `chunk_overlap=200`

已觀察到的結果

- Model A 建庫切塊數：Apple 11、Tesla 628
- Model B 建庫切塊數：Apple 11、Tesla 628

差異說明

- 在相同 chunk 設定下，**切塊數量不會因 embedding model 改變**（因為切塊由 splitter 決定）。
- embedding model 會影響的是向量語意空間與檢索品質，進而影響最終回答品質。

Benchmark 2

LangChain（Legacy / ReAct）

- 優點：結構單純、實作快、可快速建立 baseline。
- 缺點：多步驟流程控制較弱，路由/改寫/重試邏輯不易拆分管理。

LangGraph（Graph Workflow）

- 優點：可把流程拆成節點（retrieve -> grade -> rewrite/generate），可明確控制條件分支與重試。
- 優點：可觀察性較高，容易檢查每一步狀態與失敗點。
- 缺點：需要更多流程設計成本（state、節點轉移、條件邏輯）。

結論

- 若目標是快速 baseline：LangChain 較快。
- 若目標是可控性、可擴充性與自我修正：LangGraph 明顯更合適本作業情境。

Benchmark 3

已完成的切塊實驗

- `chunk_size=500, chunk_overlap=100`
  - Apple 21、Tesla 1221
- `chunk_size=1000, chunk_overlap=200`
  - Apple 11、Tesla 628

影響分析

- **小 chunk（例如 500）**
  - 優點：定位精細，較容易命中特定欄位或單一數值（較高 Context Precision）。
  - 缺點：表格上下文容易被切散，跨欄位推理能力下降（較低 Context Completeness）。
- **大 chunk（例如 2000）**
  - 優點：保留更多連續表格上下文，較利於完整理解財報表格（較高 Context Completeness）。
  - 缺點：可能混入較多無關內容，降低局部命中精準度（較低 Context Precision）。

對大型表格題的結論

- 當問題需要整體表格脈絡（例如比較多欄位或同表多列），較大 chunk 通常更有利。
- 當問題只要單一欄位精確值時，較小 chunk 通常更精準。